

10.1

ابتدا به اندازه k قسمت از $m_H(\epsilon/2)$ برمی‌داریم که $0 < \epsilon < 1$ و هر بار A رو روی قسمت‌ها اعمال می‌کنیم تا به مجموعه $\hat{H} := \{\hat{h}_1, \dots, \hat{h}_k\}$ برسیم. با توجه به اینکه احتمال $\min_{i \in [k]} L_D(\hat{h}_i) \leq \min L_D(h) + \epsilon/2$ می‌باشد یک ERM روی H اعمال می‌کنیم و داده‌های آموزشی آخرین قسمت k تایی با سایز زیر باشند:

$$\left\lceil \frac{2 \log(4k/\delta)}{\epsilon^2} \right\rceil$$

با وجود h داریم: $L_D(\hat{h}) \leq \min_{i \in [k]} L_D(h_i) + \epsilon/2$
و با اعمال union bound می‌رسیم که با احتمال $1 - \delta$

$$\begin{aligned} L_{\mathcal{D}}(\hat{h}) &\leq \min_{i \in [k]} L_{\mathcal{D}}(h_i) + \epsilon/2 \\ &\leq \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h) + \epsilon. \end{aligned}$$

10.4

a.

فرض کنید X یک مجموعه محدود به اندازه n باشد. فرض کنید B کلاس همه توابع از X تا $\{0, 1\}$ باشد. سپس $L(B, T) = B$ و هر دو متناهی هستند. بنابراین، برای هر $T \geq 1$:
 $VCdim(B) = VCdim(L(B, T)) = \log 2^n = n$

b.

$$B = \{h_{j,b,\theta} : j \in [d], b \in \{-1, 1\}, \theta \in \mathbb{R}\}$$

اگر

$$h_{j,b,\theta}(x) = b \cdot \text{sign}(\theta - x_j).$$

بنابراین:

$$j \in [d], \text{let } B_j = \{h_{b,\theta} : b \in \{-1, 1\}, \theta \in \mathbb{R}\}$$

$$VCdim(B_j) = 2$$

C.

با توجه به راهنمایی، برای هر $i \in [Tk/2]$ فرض کنید $x_i = \lfloor i/k \rfloor A_i \rightarrow$.
ما ادعا می کنیم که $C = \{x_i : i \in [Tk/2]\}$ توسط $\text{shatter } L(B_d, T)$ می شود فرض کنید $I \subseteq [Tk/2]$.

سپس $I = I_1 \cup \dots \cup I_{T/2}$ ، که I_t زیر مجموعه از $\{(t-1)k+1, \dots, tk\}$ است. For each $t \in [T/2]$.
فرض کنید I ستون مربوطه A است (یعنی $A_{i,j} = 1$ if $(t-1)k + i \in I_t$ (i.e., $A_{i,j} = 1$ if $(t-1)k + i \in I_t$).
بنابراین:

$$h(x) = \text{sign}((h_{j_1, -1, 1/2} + h_{j_1, 1, 3/2} + h_{j_2, -1, 3/2} + h_{j_2, 1, 5/2} + \dots + h_{j_{T/2-1, -1, T/2-3/2} + h_{j_{T/2-1, 1, T/2-1/2} + h_{j_{T/2}, -1, T/2-1/2})(x))$$

اگر باشد انگاه $h(x_i) = 1$ if $i \in I$ سپس خواهیم داشت $h \in L(B_d, T)$

11.1

فرض کنید S یک i.i.d باشد. فرض کنید h خروجی الگوریتم یادگیری توصیف شده باشد. میدانیم که مستقل از (S) ، $LD(h) = 1/2$ زیرا h یک تابع ثابت است.
فرض کنید $L_v(h)$ را محاسبه کنیم. فرض کنید که برابری S 1 باشد. مقداری برابر $\{(x, y)\} \subseteq S$ را ثابت کنید. ما بین دو حالت تمایز قائل می شویم:
• برابری $S \setminus \{x\}$ 1 است. نتیجه این است که $y = 0$ هنگامی که با استفاده از $S \setminus \{x\}$ آموزش می بینید، الگوریتم پیش بینی کننده ثابت $h(x) = 1$ را خروجی می دهد. بنابراین، leave one out با استفاده از این فولد 1 است.
• برابری $S \setminus \{x\}$ صفر است. نتیجه این است که $y = 1$ هنگامی که با استفاده از $S \setminus \{x\}$ آموزش می بینید، الگوریتم ثابت $h(x) = 0$ را خروجی می دهد. بنابراین، leave one out با استفاده از این فولد 1 است. به طور میانگین بر روی دسته ها، تخمین خطای h برابر 1 است. در نتیجه، تفاوت بین برآورد و خطای واقعی 0.5 است. موردی که در آن برابری S صفر است به طور مشابه درست است.

18.2

آنتروپی باینری را با H نشان می دهیم. الگوریتم اولین ریشه رامیگیرد با جستجوی بیشترین Information gain و IG برای فیچر اول

$$H\left(\frac{1}{2}\right) - \left(\frac{1}{2}H\left(\frac{1}{2}\right) + \frac{1}{2}H\left(\frac{1}{2}\right)\right) = 0.$$

و برای فیچر دوم و سوم :

$$H\left(\frac{1}{2}\right) - \left(\frac{3}{4}H\left(\frac{2}{3}\right) + \frac{1}{4}H(0)\right) \approx 0.22$$

بنابراین الگوریتم $x_1 = 0$ را انتخاب به عنوان ریشه انتخاب میکند اما این بدان معنی است که سه مثال $((1,0,0),1)$ و $((1,1,0),0), ((1,1,1),1)$ ، از یک زیر درخت پایین می روند و مهم نیست که اکنون چه سؤالی بپرسیم، نمی توانیم هر سه نمونه را به طور کامل طبقه بندی کنیم. به عنوان مثال، اگر $x_2 = 0$ باشد (پس از آن باید یک پیش بینی ارائه کنیم)، یا $((1,1,0),0)$ یا $((1,1,1),1)$ لیبیل اشتباه می شوند. بنابراین در هر صورت حداقل یک نمونه به اشتباه برچسب گذاری می شود. از آنجایی که در مجموعه آموزشی 4 نمونه داریم، نتیجه این است که خطای آموزش حداقل $1/4$ است. بنابراین یک درخت 5 راسی خواهیم داشت که ریشه بررسی میکند $x_2=0$ است یا خیر بعد داده های رووس بعدی با سوال $x_3=0$ افراز میشوند .